

Avanzamento esperimenti

Qwen3-VL su Video-MME e LVBench

1 · marker_24 — il segnale consegnato come token

pass 1 · 24 frame uniformi, un forward con cattura attenzione
domanda → *token visivi* → cella di picco

pass 2 · gli stessi frame, blocco video spezzato sui confini di cella



24 frame = 12 celle. I marcatori racchiudono la cella — cioè 2 frame, non uno: è la risoluzione reale del segnale, e i tagli devono cadere su confini di cella o il processor paddea e sfasa tutti i timestamp.

```
...<|vision_end|><START_IMPORTANT_FRAME><4.5 seconds><|vision_start|>[frame]<|vision_end|> <5.5 seconds><|vision_start|>[frame]  
<|vision_end|><END_IMPORTANT_FRAME><6.5 seconds>...
```

Prompt:

Focus on the frames enclosed between <START_IMPORTANT_FRAME> and <END_IMPORTANT_FRAME>: that is where the visual evidence relevant to the question is.

Anteposta al prompt MCQ. Il controllo `random` riceve la stessa identica istruzione, con la cella scelta a sorte.

knob	valore
query_rows	question
sink_filter	false — attenzione grezza
top_k	1 cella
always_highlight	true — nessun gate
costo vs baseline	3.2×

2 · visual_prompt_24 — lo stesso segnale come pixel

pass 1 · identico

pass 2 · i 24 frame estratti in PNG, la parola **IMPORTANT** dipinta sui 2 frame della cella



Entrambi i frame della cella, perché il patch embedding è 3D e i due si fondono in una riga di token.



Frame dipinto alla geometria del fullset: `bottom` , `height_frac=0.12` .

knob	valore
query_rows	entity — sole righe del soggetto
sink_filter	true — token-sink azzerati
top_k	1 cella
geometria	bottom, 12% dell'altezza
costo vs baseline	3.5x

entity : Vedi slide successiva

Prompt:

Some frames have the word IMPORTANT written on them; those frames contain the visual evidence relevant to the question. Do not mention the word in your answer.

Anteposta al prompt MCQ. L'ultima frase evita che la parola finisca nella risposta e sporchi il parsing MCQ.

3 · Il knob `query_rows=entity`

Quali righe della domanda entrano nella media dell'attenzione

passo	cosa fa
1	taglio del prompt a <code>options:</code> → resta la sola domanda
2	chiamata solo-testo al decoder già in memoria — greedy, 32 token, system + 3 esempi few-shot
3	output atteso: una sequenza contigua verbatim, oppure <code>NONE</code>
4	match verbatim nella domanda → righe di quei token

esito (900 sample)	quota	righe usate
entity mappata	63%	token del soggetto
<code>NONE</code> — domanda senza soggetto	18%	fallback → <code>question</code>
non mappa verbatim	19%	fallback → <code>question</code>

Nessun secondo modello in memoria, nessun costo di caricamento. Il fallback è tracciato per sample (`query_rows_mode` , `entity_mapped` , `entity_raw`): l'effetto entity è quindi misurato diluito — su 900 sample solo 566 girano davvero a righe-entità. Il confronto interno attention/random non ne soffre: entrambi i rami usano lo stesso mix.

You extract THE SUBJECT of a question: the single entity or action the question is about. Copy it EXACTLY as written in the question: ONE contiguous sequence of one or more words. Prefer the shortest sequence that names the subject. Do NOT answer the question. If the question has no specific subject, output NONE.

+ 3 esempi few-shot: "...jacket worn by the man playing the guitar?" → jacket · "What is this video mainly about?" → `NONE`

<code>query_rows</code>	righe mediate
<code>all</code> (regime storico)	100% del prompt
<code>question</code>	~24%
<code>entity</code>	~11%

Le opzioni restano fuori dall'input dell'estrattore: con le opzioni in contesto il prior "MCQ → rispondi" di un 2B domina qualsiasi istruzione, e il modello sputava un'opzione invece del soggetto (8/60 utili). Togliere il grilletto batte l'istruzione.

4 · Arm su Video-MME — Qwen3-VL-2B (2700 sample)

arm	gate	query_rows	sink_filter	pooled	Δ	short	medium	long
baseline_24	—	—	—	54.44% (1470)	—	66.89%	52.33%	44.11%
entropy_shift_24	> 0.7	all	true	55.00% (1485)	+0.56	67.78%	52.11%	45.11%
marker_24 (attention)	nessuno	question	false	53.04% (1432)	-1.41	66.33%	49.56%	43.22%
marker_random_24 (random)	nessuno	question	false	53.11% (1434)	-1.33	66.44%	49.89%	43.00%
visual_prompt_24 (attention)	nessuno	entity	true	53.48% (1444)	-0.96	65.89%	51.44%	43.11%
visual_prompt_24_rand (random)	nessuno	entity	true	53.52% (1445)	-0.92	66.22%	50.78%	43.56%

nessuno = always_highlight: true : si interviene sul 100% dei sample, nessuno è esente (da cui il costo 3.2× / 3.5×).

coppia treatment – controllo	Δ	in sample	entropy_shift_24 — il solo con gate	quota	accuracy
marker_24 – marker_random_24	-0.07 pp	-2 / 2700	gate aperto (entropia > 0.7) → pass 2	53.70% (1450)	37.86%
visual_prompt_24 – visual_prompt_24_random	-0.04 pp	-1 / 2700	gate chiuso → risposta del pass 1	46.30% (1250)	74.88%

Dove vanno le risposte — rispetto al pass 1, visual_prompt

	rotti (dei corretti al pass 1)	recuperati (degli sbagliati)	netto
visual_prompt_24 (attention)	156 / 1476 (10.6%)	123 / 1223 (10.1%)	-33
visual_prompt_24_random (random)	151 / 1477 (10.2%)	119 / 1223 (9.7%)	-32

SE della differenza: ±1.36 pp sul pooled, ±2.35 pp per fascia.

5 · Scala del modello — baseline 2B vs 4B (2700 sample)

	Qwen3-VL-2B	Qwen3-VL-4B	Δ	intervento	Δ accuracy	costo
pooled	54.44% (1470/2700)	58.85% (1589/2700)	+4.41	entropy_shift_24 (2B)	+0.56 pp	2.70×
short	66.89%	69.00%	+2.11	marker_* (2B)	−1.4 pp	3.2×
medium	52.33%	56.78%	+4.44	visual_prompt_* (2B)	−0.9 pp	3.5×
long	44.11%	50.78%	+6.67	passare al 4B	+4.41 pp	1.07×
latenza (shard L40S)	3.32 s	3.54 s	+6.6%			

z = 3.27 (p ≈ 0.0011)

Stesso arm sui due modelli (entropy_shift_24)

	Qwen2.5-VL-3B	Qwen3-VL-2B
baseline_24 → entropy_shift_24	55.04% → 55.63% (+0.59)	54.44% → 55.00% (+0.56)
% resampling	73.15%	53.70%
costo arm / baseline	1.69×	2.70×
sovraccosto per sample ricampionato	3.54 s	10.5 s

6 · Oracolo su LVBench (100 sample, 24 frame)

condizione	quali frame vede	come riceve l'indicazione	da dove viene l'indicazione	accuracy	Δ	appaiato
baseline	24 uniformi	—	—	32%	—	—
peak	24 uniformi	puntatore nel prompt	cella di picco (segnale del modello)	29%	−3	+4 / −7
oracle	24 uniformi	puntatore nel prompt	finestra annotata (verità)	30%	−2	+5 / −7
zoom	24 dentro la finestra	i frame stessi	finestra annotata (verità)	48%	+16	+22 / −6

Focus on the part of the video between 880 and 1100 seconds: that is where the visual evidence relevant to the question is.

Il puntatore di `peak` e `oracle` : una frase anteposta al prompt MCQ, frame invariati. Si indica l'intervallo della cella (~220 s a `nframes=24`), non un istante: è la risoluzione vera del segnale.

Due assi, non quattro condizioni sparse: **quale informazione** (il picco che il modello stima, contro la finestra vera annotata) × **come gliela consegna** (dirglielo, contro cambiare i frame che vede).

confronto	isola	esito
peak → oracle	informazione migliore, stessa consegna	29% → 30%: l'informazione perfetta non paga
oracle → zoom	stessa informazione, consegna diversa	30% → 48%: paga la consegna

`qwen3_vl_2b_attn` · job 94348 · MCQ a 4 opzioni (livello di caso 25%) · `peak` e `oracle` usano lo stesso identico testo di puntatore (`POINTER_SPAN_SEC`): fra loro cambia solo *dove* punta, mai *come* parla · dettagli in `docs/oracolo_lvbench.md`