

Marcare o ricampionare

Qwen3-VL su Video-MME e LVBench

```
qwen3_vl_2b_attn · greedy ( generation=precise ) · seed=42 · nframes=24
```

Video-MME intero senza sottotitoli, 3 shard da 900 — accuracy pooled (Σ corretti / Σ campioni)

2026-09-01

1 · Arm su Video-MME — Qwen3-VL-2B (2700 sample)

arm	query_rows	sink_filter	pooled	Δ	short	medium	long
baseline_24	—	—	54.44% (1470/2700)	—	66.89%	52.33%	44.11%
entropy_shift_24	all	true	55.00% (1485/2700)	+0.56	67.78%	52.11%	45.11%
marker_24 (attention)	question	false	53.04% (1432/2700)	−1.41	66.33%	49.56%	43.22%
marker_random_24 (random)	question	false	53.11% (1434/2700)	−1.33	66.44%	49.89%	43.00%
visual_prompt_24 (attention)	entity	true	53.48% (1444/2700)	−0.96	65.89%	51.44%	43.11%
visual_prompt_24_random (random)	entity	true	53.52% (1445/2700)	−0.92	66.22%	50.78%	43.56%

coppia treatment – controllo	Δ	in sample
marker_24 – marker_random_24	−0.07 pp	−2 / 2700
visual_prompt_24 – visual_prompt_24_random	−0.04 pp	−1 / 2700

Dove vanno le risposte — rispetto al pass 1, visual_prompt

	rotti (dei corretti al pass 1)	recuperati (degli sbagliati)	netto
visual_prompt_24 (attention)	156 / 1476 (10.6%)	123 / 1223 (10.1%)	−33
visual_prompt_24_random (random)	151 / 1477 (10.2%)	119 / 1223 (9.7%)	−32

SE della differenza: ±1.36 pp sul pooled, ±2.35 pp per fascia.

2 · Scala del modello — baseline 2B vs 4B (2700 sample)

	Qwen3-VL-2B	Qwen3-VL-4B	Δ	intervento	Δ accuracy	costo
pooled	54.44% (1470/2700)	58.85% (1589/2700)	+4.41	entropy_shift_24 (2B)	+0.56 pp	2.70×
short	66.89%	69.00%	+2.11	marker_* (2B)	−1.4 pp	3.2×
medium	52.33%	56.78%	+4.44	visual_prompt_* (2B)	−0.9 pp	3.5×
long	44.11%	50.78%	+6.67	passare al 4B	+4.41 pp	1.07×
latenza (shard L40S)	3.32 s	3.54 s	+6.6%			

z = 3.27 (p ≈ 0.0011)

Stesso arm sui due modelli (entropy_shift_24)

	Qwen2.5-VL-3B	Qwen3-VL-2B
baseline_24 → entropy_shift_24	55.04% → 55.63% (+0.59)	54.44% → 55.00% (+0.56)
% resampling	73.15%	53.70%
costo arm / baseline	1.69×	2.70×
sovraccosto per sample ricampionato	3.54 s	10.5 s

3 · Oracolo su LVBench (100 sample, 24 frame)

condizione	accuracy	Δ	appaiato	p (McNemar esatto)
baseline — 24 frame uniformi	32%	—	—	—
peak — puntatore alla cella di picco	29%	-3	+4 / -7	0.55
oracle — puntatore alla finestra vera	30%	-2	+5 / -7	0.77
zoom — 24 frame dentro la finestra vera	48%	+16	+22 / -6	0.0037

confronto diretto fra le due metà	appaiato	p
zoom - oracle (stessa informazione, due consegne)	+23 / -5	0.0009

qwen3_vl_2b_attn · job 94348 · MCQ a 4 opzioni (livello di caso 25%) · dettagli in docs/oracolo_lvbench.md

4 · Dove vive il guadagno di zoom

	n	baseline	zoom
finestra con < 1 frame atteso nel campione uniforme	77	27%	49%
finestra con ≥ 1 frame atteso	23	48%	43%

Tutti e 22 i sample recuperati da zoom stanno nel primo gruppo.

regime LVBench	valore
durata mediana del video	71 min
finestra d'evidenza annotata, mediana	30 s (0.8% del video)
frame attesi dentro la finestra con 24 frame uniformi (mediana)	0.20
sample con < 1 frame atteso	77 / 100
copertura della finestra — 24 frame / 48 frame	45% / 51%

5 · Il segnale d'attenzione, misurato senza accuracy

Hit = la cella di picco interseca la finestra annotata (job 93613, 60 sample)

rowset	hit	livello di caso
all	28.3%	15.8%
question	28.3%	15.8%
entity	30.0%	15.8%

Su 100 sample: 31% contro 18.8% atteso, $z = 4.21$.

Sui 22 sample recuperati da zoom : 4 / 22 (18%).

Allargare la finestra attorno al picco

finestra	% del video	copre	caso	lift	frame nell'evidenza
±0 (solo picco)	8%	31%	18%	1.68×	2.4
±1	25%	41%	32%	1.27×	0.8
±2	42%	54%	45%	1.21×	0.5
±3	58%	59%	55%	1.07×	—

Distanza picco → finestra (100 sample, job 94348)

distanza (celle)	0	1	2	3	4	5+
sample	31	10	13	5	3	38

6 · Sintesi

direzione	stato	evidenza
marcare (<code>attention_highlight</code> / <code>attention_marker</code> / <code>visual_prompt</code>)	chiuso	3 canali, 3 controlli random, tutti a ≈ 0 (-2 e -1 sample su 2700); oracolo 30% contro baseline 32%
affilare il segnale (<code>query_rows</code> , <code>sink_filter</code>)	esaurito	grezzo e raffinato pareggiano entrambi il proprio controllo; hit-rate invariato fra rowset (28.3 / 28.3 / 30.0)
ricampionare	aperto	unico arm sopra baseline (+0.56 pp); soffitto misurato +16 pp ($p = 0.0037$)
localizzare la finestra	collo di bottiglia	il picco la trova nel 18% dei casi in cui il guadagno vive; oltre 1 cella la distanza è quasi piatta
scala del modello	riferimento	+4.41 pp ($z = 3.27$) per +6.6% di costo

Prossimo giro — `coarse_to_fine` su LVBench, tre lanci

lancio	ruolo
arm	zoom iterativo guidato da attenzione (dove) ed entropia (quando fermarsi)
controllo <code>random</code>	stessa struttura, stessi passi, stesso budget: cambia solo da dove viene la regione
<code>uniform</code> a 48 frame	controllo a budget pari: se l'arm lo pareggia, il guadagno è budget e non segnale