

Risposte ai task del 02/09

Qwen3-VL-2B su LVBench e Video-MME

Cinque punti su sette rispondibili dai dati già su wandb. Due richiedono il full-set.

1 · L'attenzione trova la finestra?

$\Pr(a > \tau \mid \text{window_T}) > \Pr(a > \tau \mid \text{window_F})$ — `signals_512p` , 512 frame, 256 celle temporali, 69/100 sample usabili, mediana 2 celle vere per sample (caso top-1 = 1.6%)

Il ranking funziona — $\text{AUC} = \Pr(\text{cella dentro la finestra} > \text{cella fuori})$; $\text{hit}@k$ = la finestra è fra le k celle più attenzionate

rowset · massa	AUC	rango mediano	hit@1	hit@5	hit@10	hit@25
all raw	0.775	10	17%	38%	52%	67%
all sink-filtered	0.758	11	17%	36%	49%	61%
question raw	0.742	13	16%	36%	48%	62%
last_token raw	0.746	25	4%	10%	25%	51%
<i>caso</i>	<i>0.500</i>	<i>128</i>	<i>1.6%</i>	<i>7%</i>	<i>13%</i>	<i>26%</i>

Non è un artefatto

	AUC	hit@1
controllo		
posizione	0.552	1%
permutazione	0.518 ± 0.025	2.3%

posizione: un profilo medio, identico per ogni sample — sa solo *dove* di solito va l'attenzione, non guarda il video. **permutazione**: il vettore d'attenzione di un altro sample, 200 giri.

La disuguaglianza vale ed è robusta: il bias di posizione spiega quasi nulla (AUC 0.552) e non basta un vettore d'attenzione qualsiasi (0.518), serve quello di *quel* video. Il segnale resta però **debole in assoluto**: col top-10 la finestra entra nel 52% dei sample contro il 13% del caso. `sink_filtered` peggiora su ogni rowset.

Il test diretto

hit@1 reale **12/69** contro **1.1** attesi dal caso — binomiale $p = 7.8 \cdot 10^{-10}$

2 · Il gate d'entropia

H = entropia ($\log_2$) della softmax **ristretta alle 4 lettere candidate**, al pass 1 — 0 bit = certezza assoluta, 2 bit = le quattro opzioni equiprobabili ·
signals_512p , additive , entropy_shift_24

AUROC(H) = $\Pr(H \text{ di una risposta } \textbf{sbagliata} > H \text{ di una risposta } \textbf{giusta})$, prese a caso una per gruppo; pareggi contati

0.5. **0.5 = H non distingue**, 1.0 = separazione perfetta.

dataset · run	n	accuracy	H mediana	2^H	H se giusta	H se sbagliata	distanza	AUROC(H)
Video-MME · entropy_shift_24	2700	55.0%	0.826	1.77 di 4	0.566	1.119	0.553	0.746
LVBench · additive pass 1	200	35.0%	1.345	2.54 di 4	1.040	1.263	0.223	0.592
LVBench · signals_512p	100	43.0%	1.389	2.62 di 4	1.112	1.220	0.108	0.547

2^H = fra quante delle 4 opzioni il modello sta di fatto esitando. **distanza** = quanto si separano le due entropie medie: è ciò che AUROC misura.

3 · Accuracy per question type — LVBench

In attesa del full-set. Le righe sono le quattro misure appaiate che la run `lvbench-additive-full` produce sullo stesso sample.

condizione	frame	n	tot	entity recog.	event underst.	key info retr.	reasoning	summariz.	temporal ground.
baseline (pass 1)	256	1548	—	—	—	—	—	—	—
k10	512	1548	—	—	—	—	—	—	—
k5	512	1548	—	—	—	—	—	—	—
rand10 (controllo)	512	1548	—	—	—	—	—	—	—

Perché la tabella è vuota — gli n per tipo di oggi, e quelli attesi sul full-set

tipo	n oggi (su 200)	1 sample vale	n atteso (su 1548)	1 sample varrà
entity recognition	92	1.1 pp	≈ 712	0.14 pp
event understanding	72	1.4 pp	≈ 557	0.18 pp
key information retrieval	41	2.4 pp	≈ 317	0.32 pp
reasoning	29	3.4 pp	≈ 224	0.45 pp
temporal grounding	23	4.3 pp	≈ 178	0.56 pp
summarization	8	12.5 pp	≈ 62	1.61 pp

I `question_type` sono **multi-label**: un sample può contare in più tipi, quindi la colonna somma a più del numero di sample (265 su 200). Gli **n attesi** sono la proporzione di oggi riscalata a 1548, non una misura: gli shard sono strided su una lista shuffled, quindi il mix dei tipi resta lo stesso in attesa.

4 · I token «sink»

signals_512p , 100/100 sample, 28 layer, hidden 2048. Candidati 1793 · 1999 · 1401 contro controlli a caso 684 · 1316 · 1939 .

I canali esistono — distribuzione di $|h[d]|$, layer 7-21

canale	intervallo modale	quota $ h >50$
d1999 · candidato	[100, 158) — 63.2%	99.84%
d1793 · candidato	[40, 63) — 45.9%	62.07%
d1401 · candidato	[6, 10) — 25.7%	0.00%
d684 · controllo	[2, 3) — 21.9%	0.00%
d1316 · controllo	[3, 4) — 22.7%	0.00%
d1939 · controllo	[2, 3) — 21.9%	0.00%

I token no — $|h[d]|$ / media($|h|$)


canale	token sink	token non-sink
d1999	58.91	47.08
d1793	20.41	18.89
d1401	2.45	2.25
d684 · ctrl	0.79	0.75

Il canale è acceso su **tutti** i token: è una proprietà del layer, non di un sottoinsieme.

I **canali** outlier esistono, i **token** sink no: assorbono *meno* attenzione di quanta ne spetterebbe loro a caso. Non c'è un percentile giusto perché non c'è niente da filtrare.

La prova che chiude — massa d'attenzione sui top-p% token per sink score

rowset	p=1%	p=2%	p=5%	p=10%	p=25%	p=50%
all	0.8%	1.6%	3.7%	7.2%	18.4%	39.2%
question	0.7%	1.4%	3.3%	6.5%	16.8%	37.0%
last_token	1.1%	2.1%	4.6%	8.8%	22.3%	47.2%
atteso se pozzi	>1%	>2%	>5%	>10%	>25%	>50%



Heatmap — nessuna struttura

mappa	intervallo	escursione
temporale (256 celle)	26.07 - 29.02	11%
spaziale (griglia 5×9)	26.06 - 28.46	9%

6 · Accuracy per task type — Video-MME (2700 sample)

modello · arm	tot	act.reas	act.recog	attr.perc	counting	info.syn	obj.reas	obj.recog	ocr	spat.perc	spat.reas	temp.perc	temp.reas
4B baseline_24	58.9%	49.5	55.3	71.6	42.2	74.6	55.5	65.5	61.2	70.4	73.2	65.5	44.1
2B baseline_24	54.4%	44.2	53.0	66.2	38.4	73.1	49.3	61.6	58.3	63.0	66.1	61.8	36.2
2B entropy_shift_24	55.0%	46.3	54.3	67.6	37.3	71.8	50.0	62.4	62.6	61.1	64.3	54.5	37.9
2B visual_prompt_24	53.5%	44.9	52.1	64.4	38.1	69.0	50.2	62.1	54.0	57.4	67.9	54.5	35.6
2B visual_prompt_24_random	53.5%	44.9	51.1	66.2	37.3	69.3	49.3	62.1	54.7	59.3	69.6	56.4	36.2
2B marker_24	53.1%	43.2	52.4	65.3	35.8	71.2	48.7	61.3	53.2	59.3	67.9	58.2	35.0
3B baseline_24double	56.9%	50.9	54.3	71.6	35.8	72.4	55.7	62.1	59.7	59.3	71.4	60.0	40.7
3B baseline_24	55.0%	53.0	51.8	65.3	33.6	71.2	54.0	57.9	59.7	61.1	67.9	63.6	39.0
3B highlight_top1_24	54.6%	51.9	50.2	64.0	39.2	71.2	52.4	57.9	58.3	61.1	71.4	54.5	37.3
<i>n per tipo</i>	<i>2700</i>	<i>285</i>	<i>313</i>	<i>222</i>	<i>268</i>	<i>323</i>	<i>454</i>	<i>354</i>	<i>139</i>	<i>54</i>	<i>56</i>	<i>55</i>	<i>177</i>

per durata	short	medium	long	intervento	Δ
4B baseline_24	69.0%	56.8%	50.8%	2B entropy_shift_24 vs baseline	+0.6 pp
2B baseline_24	66.9%	52.3%	44.1%	2B visual_prompt_24 vs baseline	−0.9 pp
2B entropy_shift_24	67.8%	52.1%	45.1%	2B marker_24 vs baseline	−1.3 pp
2B marker_24	66.4%	49.9%	43.0%	2B → 4B	+4.5 pp

Il profilo per task type è quasi **invariante all'arm**: le differenze fra righe sono molto più piccole di quelle fra colonne.

`visual_prompt_24` e il suo controllo `random` fanno **53.5% entrambi**. Il salto è la capacità del modello, non l'intervento.

7 · Tabella completa dei risultati

docs/risultati-260919.xlsx — 101 run di eval lette da wandb, aggregate per shard in **60 esperimenti**. Solo numeri.

I quattro fogli

foglio	contenuto	righe
Risultati	dataset · modello · arm · setting · frame · shard · n · corretti · accuracy · latency · job · data	60
VideoMME_task_type	12 task type, solo full-set	19
VideoMME_durata	short / medium / long	19
LVBench_question_type	6 question type + gli n	3

Copertura

progetto	run di eval
Video-MME	87
LVBench	12
MVBench	1
EgoSchema	1

Full-set, ordinati

dataset	modello · arm	frame	n	acc
MVBench	2.5-3B uniforme	32	3748	64.8%
EgoSchema	2.5-3B uniforme	64	500	62.6%
Video-MME	2.5-3B entropy_attn	128	2700	60.2%
Video-MME	2.5-3B uniforme	128	2700	59.9%
Video-MME	3-4B baseline_24	24	2700	58.9%
Video-MME	2.5-3B baseline_24double	24	2700	56.9%
Video-MME	3-2B entropy_shift_24	24	2700	55.0%
Video-MME	3-2B baseline_24	24	2700	54.4%
Video-MME	3-2B visual_prompt_24	24	2700	53.5%
Video-MME	3-2B marker_24	24	2700	53.1%
LVBench	2.5-3B uniforme	768	1033	44.2%

Su LVBench con Qwen3-VL-2B **non esiste nessuna run full-set**: tutte probe da 100-200 sample (topk 45.0%, signals_512p 43.0%, baseline_48 40.0%, additive pass 1 35.0%), non confrontabili fra loro.

Il metodo · campionamento a coppie e arm additivo

1 · Celle indirizzabili — `utils/pair_sampling.py`

Qwen3-VL fonde i frame **a due a due** (`temporal_patch_size=2`): una cella d'attenzione è una coppia di frame **adiacenti nella lista**. Campionando uniformemente su LVBench (mediana 71 min) i due frame di una cella distano minuti — la cella non corrisponde a nessun istante.



uniforme: le coppie cadono a caso nel tempo



a coppie: centri uniformi $c_i = D \cdot (i+0.5)/n$, due frame a $c_i \pm \text{gap}/2$ (gap = 2 s)

Ogni cella è una coppia e il suo timestamp è c_i , lo stesso che il processor scrive nel prompt. Le celle diventano **indirizzabili**: «la cella 37 è al secondo 1024». È ciò che rende misurabile T1 e possibile il puntamento.

Il gate già passato — probe oracolo, 92 sample, iso-budget 512 frame

condizione	accuracy	Δ
base256	41.3%	—
uniform512	41.3%	+0.0
oracle512	54.3%	+13.0 pp

2 · Arm additivo top-k — `strategies/additive_topk.py`

L'arm **sostitutivo** (`topk_resample`) è stato falsificato: rimpiazzare 512 frame con 128 butta più contesto di quanto la zoomata aggiunga — un miss costa −11.9 pp, un hit vale +23, e con hit@1 al 17% il conto è negativo. Qui il termine negativo **sparisce per costruzione**: la base resta, i frame mirati si **sommano**.



pass 1 · 256 frame base = 128 celle → ranking per massa d'attenzione



pass additivo · 256 frame in più, solo dentro le top-k celle

La regione di una cella è la sua **cella di Voronoi** $[D \cdot i/n, D \cdot (i+1)/n]$; celle adiacenti vengono **fuse** e il budget si divide in proporzione alla durata di ogni regione. Gli aggiunti sono **uniformi dentro la regione, non a coppie**: sul pass additivo non si rilegge nessun ranking. Un aggiunto che cade su un indice già presente viene scartato.

Raddoppiare i frame **uniformemente** vale esattamente zero: tutto il guadagno sta nel *dove*. L'arm sostituisce l'oracolo col puntatore vero.

⚠ Nella lista unita il modello accoppia frame **adiacenti nella lista**: le coppie della base non sopravvivono, quindi le celle del pass additivo **non** sono quelle del pass 1. Accettabile finché lì non si rilegge l'attenzione.

La run che chiude i due punti aperti

```
LIMIT=null GROUP=lvbench-additive-full sbatch --array=0-23 scripts/sbatch/lvbench_additive.sbatch
```

Tre condizioni appaiate, un solo decode

condizione	cosa vede	metrica
baseline	256 frame della base	mcq_accuracy
k10	+ 256 nelle top-10 celle	..._cond_k10
k5	+ 256 nelle top-5	..._cond_k5
rand10	+ 256 in 10 celle a caso	..._cond_rand10

rand10 è il controllo che decide se l'arm è un arm. Già validato: centra la finestra nel **9%** dei casi contro il **57%** di k10 .

Costo

sample	1548 (full-set)
shard	24 × ~65 sample
per shard	1.98 h (limite 3 h)
totale	47 GPU-h

Cosa chiude

punto	serve?	perché
2 · gate entropia	no	2700 + 300 sample già misurati
4 · sink	no	la prova è netta su 100 sample
6 · task type VMME	no	già full-set
7 · tabella	no	consegnata
1 · attenzione/finestra	in parte	il verso è solido, la soglia no
3 · task type LVBench	sì	4 tipi su 6 con $n < 30$
oracolo full-set	sì	due probe, segni opposti

La contraddizione da sciogliere

probe	n	esito
probe_additive_oracle	92	oracle512 +13.0 pp su uniform512
probe_oracle_ceiling	100	oracle 30% contro baseline 32%

Nella stessa probe, uniform512 = base256 **esattamente** su entrambi gli shard: raddoppiare i frame uniformi vale zero, tutto il guadagno sta nel *dove*.