

Risposte ai task del 02/09

Qwen3-VL-2B su LVBench e Video-MME

Cinque punti su sette rispondibili dai dati già su wandb. Due richiedono il full-set.

1 · L'attenzione trova la finestra?

$\Pr(a > \tau \mid \text{window_T}) > \Pr(a > \tau \mid \text{window_F})$ — `signals_512p` , 512 frame, 256 celle, 69/100 sample usabili, mediana 2 celle vere (caso top-1 = 1.6%)

Il ranking funziona

rowset · massa	AUC	hit@1	hit@5	hit@10	hit@25
all raw	0.775	17%	38%	52%	67%
all sink-filt.	0.758	17%	36%	49%	61%
question raw	0.742	16%	36%	48%	62%
<code>last_token</code> raw	0.746	4%	10%	25%	51%
<i>caso</i>	<i>0.500</i>	<i>1.6%</i>	<i>7%</i>	<i>13%</i>	<i>26%</i>
controllo				AUC	hit@1
posizione (profilo medio)				0.552	1%
permutazione (altro sample)				0.518 ±0.025	2.3%

hit@1 reale **12/69** contro 1.1 attesi — binomiale **p = 7.8e-10**

La soglia — massa in multipli della quota uniforme

τ	$\Pr(a > \tau \mid W_T)$	$\Pr(a < \tau \mid W_F)$	J	celle/sample	precis.
0.50	0.836	0.305	0.141	179	1.9%
0.93	0.615	0.672	0.286	85	2.9%
1.50	0.418	0.854	0.273	38	4.3%
3.00	0.171	0.964	0.135	10	6.9%
5.00	0.087	0.988	0.075	3	10.4%
<i>a caso</i>					<i>1.56%</i>

275 celle vere contro 17.389 false. Il massimo di Youden ($\tau=0.93$) tiene **85 celle su 256** con precisione 2.9%: J pesa sensibilità e specificità allo stesso modo, e con prevalenza 1.6% la specificità è quasi gratis.

A parità di celle, soglia $\equiv$ top-k

budget	precisione	recall	hit
top-5 · soglia $\tau=4.19$	9.6% · 9.9%	12.0% · 12.4%	38% · 39%
top-10 · soglia $\tau=2.98$	7.2% · 7.0%	18.2% · 17.5%	52% · 52%
top-25 · soglia $\tau=1.87$	5.0% · 4.9%	31.3% · 30.9%	67% · 65%

Il segnale c'è ed è significativo. Soglia e top-k **ordinano ugualmente bene**: a fallire non è la soglia ma **Youden come criterio**, il cui ottimo tiene un terzo delle celle. Si sceglie il top-k perché **fissa il budget** su ogni sample, non perché ordini meglio. `sink_filtered` peggiora su ogni rowset.

2 · Il gate d'entropia

Entropia del pass 1 sulle 4 opzioni (0-2 bit). AUROC = quanto separa le risposte **sbagliate**; 0.5 = inutile.

dataset · run	n	accuracy	H mediana	AUROC(H)
Video-MME · entropy_shift_24	2700	55.0%	0.826	0.746
LVBench · additive pass 1	200	35.0%	1.345	0.592
LVBench · signals_512p	100	43.0%	1.389	0.547

Tabella entropia → risposta corretta, per quantile di H

Video-MME (n = 2700)

quantile	soglia H	acc sotto	acc sopra	Δ
0.1	0.002	96.7%	50.4%	+46.3
0.2	0.031	90.9%	46.0%	+44.9
0.3	0.165	85.8%	41.8%	+44.0
0.5	0.825	73.0%	37.0%	+35.9
0.7	1.316	64.2%	33.5%	+30.7
0.9	1.741	57.6%	31.9%	+25.7

LVBench (n = 200)

quantile	soglia H	acc sotto	acc sopra	Δ
0.1	0.064	65.0%	31.7%	+33.3
0.2	0.572	55.0%	30.0%	+25.0
0.3	0.887	45.0%	30.7%	+14.3
0.5	1.340	41.0%	29.0%	+12.0
0.7	1.649	37.9%	28.3%	+9.5
0.9	1.845	36.7%	20.0%	+16.7

Il segnale **non si trasferisce**: su LVBench il salto esiste solo nel primo quintile e sparisce in mezzo alla distribuzione. Le scale sono diverse (H mediana 0.83 vs 1.39), quindi **una soglia assoluta non porta**: si trasferisce il **quantile**, scelto out-of-fold e raggruppato per video.

3 · Accuracy per question type — LVBench

arm	frame	n	tot	entity recog.	event underst.	key info retr.	reasoning	summariz.	temporal ground.
signals_512p	512	100	43.0%	53.8%	38.2%	46.7%	28.6%	25.0%	50.0%
topk	512	100	45.0%	53.8%	44.1%	53.3%	28.6%	25.0%	50.0%
additive pass 1	256	200	35.0%	39.1%	26.4%	41.5%	31.0%	37.5%	30.4%

Gli n per tipo — il motivo per cui la tabella sopra non si può leggere

tipo	n su 100	n su 200	1 sample vale
entity recognition	52	92	1.1 pp
event understanding	34	72	1.4 pp
key information retrieval	15	41	2.4 pp
reasoning	14	29	3.4 pp
temporal grounding	8	23	4.3 pp
summarization	4	8	12.5 pp

Quattro tipi su sei hanno $n < 30$. Con 4 sample `summarization` si muove di 25 punti per ogni risposta che cambia: 0.250 e 0.375 non sono misure. **È il punto che ha più bisogno del full-set.**

Le tre run non sono confrontabili fra loro: frame e sample diversi. `additive` è il **pass 1**, cioè la baseline senza frame aggiunti.

4 · I token «sink»

signals_512p , 100/100 sample, 28 layer, hidden 2048. Candidati 1793 · 1999 · 1401 contro controlli a caso 684 · 1316 · 1939 .

I canali esistono — distribuzione di $|h[d]|$, layer 7-21

canale	intervallo modale	quota $ h >50$
d1999 · candidato	[100, 158) — 63.2%	99.84%
d1793 · candidato	[40, 63) — 45.9%	62.07%
d1401 · candidato	[6, 10) — 25.7%	0.00%
d684 · controllo	[2, 3) — 21.9%	0.00%
d1316 · controllo	[3, 4) — 22.7%	0.00%
d1939 · controllo	[2, 3) — 21.9%	0.00%

I token no — $|h[d]|$ / media($|h|$)


canale	token sink	token non-sink
d1999	58.91	47.08
d1793	20.41	18.89
d1401	2.45	2.25
d684 · ctrl	0.79	0.75

Il canale è acceso su **tutti** i token: è una proprietà del layer, non di un sottoinsieme.

I **canali** outlier esistono, i **token** sink no: assorbono *meno* attenzione di quanta ne spetterebbe loro a caso. Non c'è un percentile giusto perché non c'è niente da filtrare.

La prova che chiude — massa d'attenzione sui top-p% token per sink score

rowset	p=1%	p=2%	p=5%	p=10%	p=25%	p=50%
all	0.8%	1.6%	3.7%	7.2%	18.4%	39.2%
question	0.7%	1.4%	3.3%	6.5%	16.8%	37.0%
last_token	1.1%	2.1%	4.6%	8.8%	22.3%	47.2%
atteso se pozzi	>1%	>2%	>5%	>10%	>25%	>50%



Heatmap — nessuna struttura

mappa	intervallo	escursione
temporale (256 celle)	26.07 - 29.02	11%
spaziale (griglia 5×9)	26.06 - 28.46	9%

6 · Accuracy per task type — Video-MME (2700 sample)

modello · arm	tot	act.reas	act.recog	attr.perc	counting	info.syn	obj.reas	obj.recog	ocr	spat.perc	spat.reas	temp.perc	temp.reas
4B baseline_24	58.9%	49.5	55.3	71.6	42.2	74.6	55.5	65.5	61.2	70.4	73.2	65.5	44.1
2B baseline_24	54.4%	44.2	53.0	66.2	38.4	73.1	49.3	61.6	58.3	63.0	66.1	61.8	36.2
2B entropy_shift_24	55.0%	46.3	54.3	67.6	37.3	71.8	50.0	62.4	62.6	61.1	64.3	54.5	37.9
2B visual_prompt_24	53.5%	44.9	52.1	64.4	38.1	69.0	50.2	62.1	54.0	57.4	67.9	54.5	35.6
2B visual_prompt_24_random	53.5%	44.9	51.1	66.2	37.3	69.3	49.3	62.1	54.7	59.3	69.6	56.4	36.2
2B marker_24	53.1%	43.2	52.4	65.3	35.8	71.2	48.7	61.3	53.2	59.3	67.9	58.2	35.0
3B baseline_24double	56.9%	50.9	54.3	71.6	35.8	72.4	55.7	62.1	59.7	59.3	71.4	60.0	40.7
3B baseline_24	55.0%	53.0	51.8	65.3	33.6	71.2	54.0	57.9	59.7	61.1	67.9	63.6	39.0
3B highlight_top1_24	54.6%	51.9	50.2	64.0	39.2	71.2	52.4	57.9	58.3	61.1	71.4	54.5	37.3
<i>n per tipo</i>	<i>2700</i>	<i>285</i>	<i>313</i>	<i>222</i>	<i>268</i>	<i>323</i>	<i>454</i>	<i>354</i>	<i>139</i>	<i>54</i>	<i>56</i>	<i>55</i>	<i>177</i>

per durata	short	medium	long	intervento	Δ
4B baseline_24	69.0%	56.8%	50.8%	2B entropy_shift_24 vs baseline	+0.6 pp
2B baseline_24	66.9%	52.3%	44.1%	2B visual_prompt_24 vs baseline	−0.9 pp
2B entropy_shift_24	67.8%	52.1%	45.1%	2B marker_24 vs baseline	−1.3 pp
2B marker_24	66.4%	49.9%	43.0%	2B → 4B	+4.5 pp

Il profilo per task type è quasi **invariante all'arm**: le differenze fra righe sono molto più piccole di quelle fra colonne.

`visual_prompt_24` e il suo controllo `random` fanno **53.5% entrambi**. Il salto è la capacità del modello, non l'intervento.

7 · Tabella completa dei risultati

docs/risultati-260919.xlsx — 101 run di eval lette da wandb, aggregate per shard in **60 esperimenti**. Solo numeri.

I quattro fogli

foglio	contenuto	righe
Risultati	dataset · modello · arm · setting · frame · shard · n · corretti · accuracy · latency · job · data	60
VideoMME_task_type	12 task type, solo full-set	19
VideoMME_durata	short / medium / long	19
LVBench_question_type	6 question type + gli n	3

Copertura

progetto	run di eval
Video-MME	87
LVBench	12
MVBench	1
EgoSchema	1

Full-set, ordinati

dataset	modello · arm	frame	n	acc
MVBench	2.5-3B uniforme	32	3748	64.8%
EgoSchema	2.5-3B uniforme	64	500	62.6%
Video-MME	2.5-3B entropy_attn	128	2700	60.2%
Video-MME	2.5-3B uniforme	128	2700	59.9%
Video-MME	3-4B baseline_24	24	2700	58.9%
Video-MME	2.5-3B baseline_24double	24	2700	56.9%
Video-MME	3-2B entropy_shift_24	24	2700	55.0%
Video-MME	3-2B baseline_24	24	2700	54.4%
Video-MME	3-2B visual_prompt_24	24	2700	53.5%
Video-MME	3-2B marker_24	24	2700	53.1%
LVBench	2.5-3B uniforme	768	1033	44.2%

Su LVBench con Qwen3-VL-2B **non esiste nessuna run full-set**: tutte probe da 100-200 sample (topk 45.0%, signals_512p 43.0%, baseline_48 40.0%, additive pass 1 35.0%), non confrontabili fra loro.

La run che chiude i due punti aperti

```
LIMIT=null GROUP=lvbench-additive-full sbatch --array=0-23 scripts/sbatch/lvbench_additive.sbatch
```

Tre condizioni appaiate, un solo decode

condizione	cosa vede	metrica
baseline	256 frame della base	mcq_accuracy
k10	+ 256 nelle top-10 celle	..._cond_k10
k5	+ 256 nelle top-5	..._cond_k5
rand10	+ 256 in 10 celle a caso	..._cond_rand10

rand10 è il controllo che decide se l'arm è un arm. Già validato: centra la finestra nel **9%** dei casi contro il **57%** di k10 .

Costo

sample	1548 (full-set)
shard	24 × ~65 sample
per shard	1.98 h (limite 3 h)
totale	47 GPU-h

Cosa chiude

punto	serve?	perché
2 · gate entropia	no	2700 + 300 sample già misurati
4 · sink	no	la prova è netta su 100 sample
6 · task type VMME	no	già full-set
7 · tabella	no	consegnata
1 · attenzione/finestra	in parte	il verso è solido, la soglia no
3 · task type LVBench	sì	4 tipi su 6 con $n < 30$
oracolo full-set	sì	due probe, segni opposti

La contraddizione da sciogliere

probe	n	esito
probe_additive_oracle	92	oracle512 +13.0 pp su uniform512
probe_oracle_ceiling	100	oracle 30% contro baseline 32%

Nella stessa probe, uniform512 = base256 **esattamente** su entrambi gli shard: raddoppiare i frame uniformi vale zero, tutto il guadagno sta nel *dove*.