

Segnali di concentrazione e router entropia/attenzione

Ricampionamento adattivo dei frame per VLM su video-MCQ


Video-MME · Qwen2.5-VL-3B · 2026-07-16

1. Obiettivo

Su un benchmark video-MCQ (Video-MME, Qwen2.5-VL-3B), il campionamento uniforme dei frame è "cieco": prende sempre lo stesso numero di frame equispaziati, a prescindere da quanto il modello sia confidente o da dove stia effettivamente guardando.

- Usare segnali che il modello produce **gratis** durante l'inferenza (nessun forward aggiuntivo oltre a quelli già necessari)
- Decidere, sample per sample:
 1. SE vale la pena ricampionare (il modello indovina o è già sicuro?)
 2. COME ricampionare, se sì (dove guardare invece di ricampionare alla cieca?)

2. Pipeline per ogni sample




I sample "accettati" sono bit-per-bit identici alla baseline `uniform` — solo il pass 2 conta per la risposta.

Punti chiave del design

- Il pass 1 costa sempre — forward di prefill completo con cattura dell'attenzione, indipendentemente dal fatto che poi si ricampioni o no. Non è "extra solo se serve".
- La risposta finale viene SEMPRE da una vera `generate()` — mai dal solo `pred_letter` della softmax ristretta del pass 1.
 - i sample "accettati" restano bit-per-bit identici alla baseline `uniform` : l'unico effetto misurabile viene dai sample effettivamente ricampionati.
- Al massimo un ricampionamento — nessun terzo pass che ri-verifichi la decisione.

3. I segnali



- **answer_entropy** = gate, indipendente dall'attenzione.
- **top1_pct** (vincitore) guarda solo il picco.
- **H_norm**
- **top1_zscore** (entrambi battuti) usano l'intera distribuzione.

3.1 answer_entropy — il segnale di GATE

Entropia di Shannon (in bit) della softmax ristretta alle sole lettere candidate (A/B/C/D...) sui logit dell'ultimo token del prefill:

$$H = - \sum_{i=1}^{n_{\text{opzioni}}} p_i \log_2 p_i$$


$H = 0 \rightarrow$ confidente

$$H = \log_2(n_{\text{opzioni}}) \rightarrow \text{sta indovinando}$$

Usato oggi come gate:

$$\text{can_resample} = \text{answer_entropy} > \tau$$

default 0.7



Pilota VNBench (30 video): separazione netta fra risposte corrette e sbagliate — $\$r = -0.75\$$, il segnale più forte fra tutti quelli provati.

3.2 top1_pct — concentrazione dell'attenzione sul frame di picco

In parole semplici: la percentuale di attenzione "pulita" (senza i token sink) che il modello dedica al SUO frame preferito — quanto si fissa su un unico istante del video invece di guardarlo tutto.

Sulla mappa di attenzione testo→visivo (già catturata dal pass 1):

1. si azzerano i token "sink" (`sink_view`) — altrimenti assorbono la maggior parte della massa indipendentemente dal contenuto
2. si aggregano le celle spazio-temporali per massa totale (`rank_cells`)
3. si prende la percentuale di massa sulla cella (frame) più attenzionata → questo è `top1_pct`

Alto → il modello "si fissa" su un frame preciso (grounding). Basso/vicino all'uniforme → attenzione dispersa su tutto il video.

Perché: correlazione più debole dell'entropia ($r = 0.58$), ma si è rivelato — dopo un confronto empirico a tre — il migliore dei segnali di concentrazione provati, nonostante sia il più "grezzo".

3.3 / 3.4 — due tentativi battuti

`H_norm` — entropia normalizzata

$$H_{\text{norm}} = \frac{H}{\log t}, \quad H = - \sum_{i=1}^t p_i \log p_i$$

0 = tutta la massa su una cella · 1 = dispersione perfettamente uniforme su t celle.

Intuizione: `top1_pct` guarda solo il picco, ignora la forma del resto della distribuzione.

Risultato: separa nella direzione giusta ma più debolmente di `top1_pct`.

`top1_zscore` — outlier per-sample

$$z = \frac{\text{top1_pct} - \mu}{\sigma}$$

μ, σ = media/dev.std delle masse per-cella dello stesso video — nessuna calibrazione esterna.

Intuizione: normalizzazione completamente per-sample, alternativa più "pulita" a una soglia fissa.

Risultato: ancora più debole di `H_norm` — il peggiore dei tre.

4. Le decisioni prese, in ordine

4.1 — Serve un gate E una decisione di ramo

Ricampionare sempre alla cieca funziona (+3.2pt vs uniform) ma un **oracolo** che sceglie il ramo giusto per sample recupera **98/163** sample, contro **83/163** del miglior ramo singolo — **+15 di margine puro dal solo instradamento**.

4.2 — Le soglie assolute fisse sono morte su Video-MME

Le soglie `concentration_threshold` $\in \{20, 30, 45\}$ (dal pilota VNBench) non discriminano più nulla: su Video-MME `top1_pct` non supera mai ~23%.

4.3 Tre segnali di concentrazione a confronto

Separazione statistica (Mann-Whitney, $|z|$) fra sample dove "zoom multi-regione" batte "fase sfasata" e viceversa — 163 sample ricampionati.

segnale	separazione $ z $	plateau accuracy /163
<code>top1_pct</code> (grezzo)	2.77	88–90
<code>H_norm</code>	2.23	85–87
<code>top1_zscore</code>	1.70	87

Riferimento: sempre-fase-sfasata = 83/163, sempre-zoom = 78/163, oracolo = 98/163.

Nessuno dei due segnali "più sofisticati" ha battuto il proxy grezzo → decisione: usare `top1_pct` .

Separazione Mann-Whitney — cos'è

Test non parametrico che confronta due gruppi indipendenti guardando i ranghi dei valori (non i valori grezzi) — non assume distribuzioni normali.

Utile qui perché `top1_pct` è fortemente non-normale (poche celle alte, coda lunga di celle quasi a zero).

Si uniscono i due gruppi, si ordinano tutti i valori e si sommano i ranghi del gruppo 1 (R_1):

$$U = R_1 - \frac{n_1(n_1 + 1)}{2}$$

Sotto l'ipotesi nulla (nessuna differenza) U ha media $\frac{n_1 n_2}{2}$ e varianza nota $\rightarrow$ si standardizza in uno z-score:

$$z = \frac{U - \frac{n_1 n_2}{2}}{\sqrt{\frac{n_1 n_2 (n_1 + n_2 + 1)}{12}}}$$

$|z|$ grande = i due gruppi sono davvero separati, non per caso.

Separazione Mann-Whitney — come l'abbiamo calcolata noi

Sui 163 sample ricampionati da entrambi i rami, 35 sono discordanti: 15 pro- `zoom_multi_region`, 20 pro- `phase_shift`. Per ciascun segnale candidato (misurato al pass 1, prima di sapere quale ramo avrebbe vinto) si confrontano i due gruppi:

	n	<code>top1_pct</code> mediana
pro- <code>zoom_multi_region</code>	15	7.60
pro- <code>phase_shift</code>	20	4.96

$$U = 233, \quad \frac{n_1 n_2}{2} = 150, \quad z = \frac{233 - 150}{\sqrt{15 \cdot 20 \cdot 36/12}} = \frac{83}{30} \approx 2.77$$

$p \approx 0.003$ — separazione altamente significativa: campioni più concentrati (`top1_pct` alto) $\rightarrow$ vince più spesso `zoom_multi_region`.

4.4 La soglia dev'essere un ratio

`top1_pct` è una percentuale su t celle: sotto attenzione uniforme ("livello di caso") il suo valore atteso è

$$\frac{100}{t}$$

Normalizzando per questo, la soglia si riscalda automaticamente fra `nframes` /dataset diversi:

$$\text{ratio} = \frac{\text{top1_pct}}{100/t}$$

$t = 64$ per `nframes` = 128, verificato su GPU reale — non solo dedotto dal codice: fattore di merge temporale a coppie del modello, $t = \text{nframes}/2$.

Soglia scelta: `concentration_ratio` = 3.85


equivalente a `top1_pct` ≈ 6.02 a $t = 64$, dentro il plateau 88–90/163

5. Cosa fa il codice OGGI

`branch_selector` — tre modalità, selezionabili senza toccare codice, additive:

<code>branch_selector</code>	condizione "disperso"	stato
<code>"concentration"</code> (default)	$\text{top1_pct} < \text{concentration_threshold}$	storico, soglia inerte
<code>"concentration_ratio"</code>	$\text{top1_pct} < \text{concentration_ratio} \cdot \frac{100}{t}$	NON generalizza al full
<code>"entropy"</code>	$H_{\text{norm}} > \text{attention_entropy_threshold}$	provato, battuto

La strada scelta: `concentration_ratio`



5.1 zoom_peak — finestra unica sul picco

1. `peak_cell` = indice della cella a massa più alta (`ranked_cells[0]`)
2. Posizione temporale frazionaria:

$$\text{frac} = \frac{\text{peak_cell} + 0.5}{t}$$

3. Mappata sulla finestra reale del pass 1 (w_0/w_1):

$$\text{peak_time} = w_0 + \text{frac} \cdot (w_1 - w_0)$$

4. Finestra stretta di semi-larghezza

$$\frac{\text{window_frac} \cdot (w_1 - w_0)}{2}$$

(default `window_frac` = 0.3 → 30%) centrata su `peak_time`, clampata a `[0, duration]`

5. Ricampiona `nframes` uniformi dentro questa finestra ristretta

Una sola regione, nessuna gestione di sovrapposizioni o budget-splitting.

5.1 zoom_multi_region — fino a n_regions finestre disgiunte

Stesso principio di zoom_peak , generalizzato a più massimi locali:

1. `_select_region_cells` — "topk" : prime `n_regions` celle. "adaptive" (default): mediana + `region_mad_k` · MAD, escludendo il picco globale (evita l'auto-mascheramento)
2. `_multi_region_spans` — centri più vicini di `region_merge_gap_frac` · ($w_1 - w_0$) fusi insieme; ogni centro → finestra di semi-larghezza fissa `region_window_frac` · ($w_1 - w_0$) (default 10%); merge finale per garantire finestre disgiunte
3. `_allocate_region_budget` — divide `nframes` fra le regioni ("equal" o "proportional" alla massa), somma sempre $\leq$ `nframes`
4. `_build_multi_region_media` — estrae i frame, calcola `sample_fps = frame totali / durata regioni usate` e impacchetta come `VideoFrames` (il modello vede i frame come uniformemente spazati, i "buchi" fra regioni spariscono)

6. Risultati sul subset 250 (seed 42)

Video-MME, subset 250 — lo stesso su cui la soglia è calibrata

strategia	accuracy	note
uniform (controllo)	62.8%	baseline
fase sfasata sempre	66.0%	+3.2pt
zoom multi-regione forzato sempre	64.0%	recupera 13 sample UNICI
oracolo (ramo giusto per sample)	~68.8%	limite superiore teorico
router <code>top1_pct</code> (<code>ratio=3.85</code>)	68.8% (172/250)	Stage C — ma non held-out

7. Full eval 2700 — il router NON generalizza

array SLURM 67691, 4 shard × 675, stessa config dello Stage C

strategia	subset 250	full 2700
uniform	62.8%	59.93%
router (<code>ratio=3.85</code>)	68.8%	60.22%
edge router – uniform	+6.0pt	+0.29pt (z=0.22, nullo)

Il router eguaglia la baseline uniform sul full.

Gap 68.8→60.2 = 8.6pt — decomposto: ~2.9pt subset più facile + ~5.7pt edge in-sample-lucky (soglia = argmax su curva piatta 88–90/163)

8. Diagnosi fine: cosa funziona e cosa è morto

✓ Il gate `answer_entropy` è l'asset

✗ Il ricampionamento è ~nullo

Split per-ramo sul full 2700:

Win/loss vs uniform pass-1 (gated):

ramo	n	accuracy
accepted (gate NO)	941	87.8%
phase_shift	891	47.4%
zoom	868	43.6%

ramo	net	note
phase_shift	+15	$\sim 1.4\sigma$, non signif.
zoom	-7	massa attn = morta
<code>zoom_multi_region</code> (massa di attenzione come finestra temporale) distrugge valore. Opzione C1 chiusa.		

Separa facile/difficile e scala con la durata (gate-fire 52%→69%→75%).

Perché il subset ingannava: mix short-skew solo +0.9pt; il resto (+7.7pt) è un draw fortunato in ogni bucket, entro $\sim 1\sigma$

9. Prossimi passi

Il *dove* temporale è saturo a 128 frame; la massa di attenzione come finestra temporale è morta. Instrumentation `pred_pass1` aggiunta → win/loss auto-riportato.

A — confermare/uccidere `phase_shift` — run phase-alone sul full, chiude il capitolo temporale con un numero (economico).

B — cambiare leva (scommessa) — la massa serve nello spazio, non nel tempo: sui gated, $2 \times \text{max_pixels}$ e/o zoom spaziale (crop della regione $grid_h \times grid_w$ a massa più alta → più risoluzione sull'oggetto).

Domande?

[docs/sintesi_segnali_router_concentrazione.md](#) — cronologia completa in [docs/piano_zoom_multiregione_disgiunto.md](#)